접수 [TO FILL]; 게재 확정 [TO FILL]; 발행 [TO FILL]; 현재 판 [TO FILL].
Digital Object Identifier 10.1109/ACCESS.2026.[TO FILL]

온디바이스 자기 학습은 언제 도움이 되는가? 스마트폰 움직임 기반 정서 추정을 위한 교차 모달 교사 신호, 무작위 프로브, 성능 가드

강정모[1], 김완태[1]

[1]서일대학교 정보통신공학과, 서울 02192

교신저자: 강정모 (e-mail: [TO FILL]).

[연구비 지원 문구 TO FILL. 없으면: 이 연구는 외부 연구비 지원을 받지 않았다.]

초록 스마트폰의 움직임으로 각성과 정서가를 단말 안에서 추정할 수 있지만, 다른 사람들로 학습한 모델은 각 사용자의 '수준'은 잘 잡아도 그 사용자 '안의 변화'는 잘 잡지 못하며, 소수의 자기보고로는 이를 고치지 못한다. 우리는 화면 사용 중 전면 카메라가 읽는 표정이라는 조밀하지만 잡음 섞인 교사가 움직임만 쓰는 학생 모델을 폰 안에서 개인화할 수 있는지 묻는다. 안드로이드에 전체 루프를 구현하고(블렌드셰이프 교사로 매시간 학습하는 33 파라미터 학생, 유일한 정답인 무작위 프로브, 히스테리시스 가드), 단말의 학습 규칙을 재현하며 교사의 정확도·밀도·편향을 통제하는 시뮬레이터로 K-EmoPhone 데이터셋의 77명을 재생했다. 답은 이득이 아니라 조건이다. 일주일 분량의 데이터에서는 잡음 없는 라벨 복사본을 쓰더라도 여섯 가지 갱신 규칙 중 어느 것도 사용자 안 AUROC를 모집단 모델 위로 올리지 못했고(각성 0.51~0.60 대 0.64), 전체 AUROC는 학생이 사용자의 수준을 배우기 때문에만 올랐다(0.62에서 0.63–0.73). 고정 임계 가드는 기본 모델보다 0.10 낮은 학생을 14일 안에 확률 0.76으로 잡아내지만 동등한 학생도 48 %의 확률로 되돌리며, 하루 세 번 프로브에서는 어떤 가드도 이 상충을 피하지 못한다. 모델이 촉발한 질문은 더 극단적인 순간을 고르고 사용자별 평가에 필요한 응답 수를 채우지 못하므로 무작위 군이 정당화된다. 32개 특징은 77명 가운데 사용자를 최대 7 %로 재식별하지만 33개 학생 가중치는 82 %로 재식별하므로, 가중치는 단말에 남아야 한다.

색인어 감성 컴퓨팅, 온디바이스 학습, 자기 학습, 모바일 센싱, 경험 표집, 성능 가드, 프라이버시, 스마트폰 가속도계.

I. 서론

스마트폰은 가속도계로 소유자의 움직임을 끊임없이 기록한다. 움직임 요약을 각성과 정서가로 사상하는 작은 모델은 단말 안에서 온전히 돌 수 있어 민감한 신호를 네트워크 밖에 두고, 콘텐츠·속도·알림을 실시간으로 조절하는 응용에 그 신호를 바로 쓸 수 있게 한다. 두 가지 장애가 있다. 첫째, 움직임에 드러나는 정서는 개인적이다. 다른 사람들로 학습한 모델은 부분적으로만 옮겨지고, 응용이 원하는 개인 내 변동은 모집단 모델이 가장 못 잡는 부분이다. 둘째, 당연한 해법인 사용자 자신의 자기보고로 모델을 개인화하는 길은 사람들이 설문에 답하는 빈도가 낮아 제한된다. 일주일 동안 하루 세 번 답하면 라벨은 약 스무 개로, 33 파라미터 모델이 사전 지식을 넘어서는 데 필요한 양에도 훨씬 못 미친다.

이 논문은 라벨의 다른 공급원을 연구한다. 화면을 쓰는 동안 전면 카메라로 표정을 추정할 수 있고, 표정은 순간 정서와의 상관이 잘 연구된 신호다. 우리는 표정에서 얻은 라벨을 움직임 특징만 쓰는 '학생' 모델의 '교사'로 삼아, 카메라가 꺼진 뒤에도 학생이 추정을 이어가게 한다. 교사는 조밀하지만(화면 사용 매분 라벨 하나) 잡음이 있고, 설문 답은 희소하지만 정확하다. 조밀한 잡음 신호로 하는 자기 학습이 희소한 정확 신호로 하는 미세 조정을 이길 수 있는가가 핵심 질문이며, 답은 교사의 정확도와 밀도에 달려 있다. 자기 학습 모델은 표류할 수도 있으므로, 모델 자신의 출력에 의존하지 않는 '무작위' 프로브에서 모집단 모델과 비교해 평가하고, 학생이 뒤처지면 모집단 모델로 되돌린다.

기여는 다음과 같다.

- **C1 (시스템).** 안드로이드 위의 완전한 온디바이스 루프: 분 단위 움직임 특징, LightGBM 모집단 모델, MediaPipe 블렌드셰이프 교사, 닫힌 형태의 기울기로 폰에서 학습하는 LiteRT 로지스틱 학생, 접촉 게이트, 두 군 질문 스케줄러(모델 촉발 A군, 무작위 B군), 히스테리시스 가드. 2018년 중급 폰에서 매시간 갱신 한 번은 수십 밀리초가 든다(VI-F절).
- **C2 (자기 학습의 조건).** K-EmoPhone 77명을 교사 정확도 p, 밀도 d, 편향 b를 통제하며 루프에 통과시키고, 학생을 고정 모집단 모델·ESM 미세 조정·사용자별 Platt 보정·오라클 교사와 비교하는 재생 시뮬레이터. 조밀한 잡음 교사가 어떤 정확도 p^* 위에서는 희소한 정확 라벨을 이긴다는 사전등록 가설은 32개 셀 어디에서도 지지되지 않았고, 더 강한 결과가 모든 접근을 제약한다. 약 일주일 분량에서는 시험한 여섯 학습기 중 어느 것도 모집단 모델보다 사용자 안 판별을 높이지 못했고, 겉으로 보이는 이득은 전체 AUROC에서만 보이는 수준 보정이었다(VI-B절).
- **C3 (가드와 선택 편향).** 하루 세 번 무작위 프로브에서 히스테리시스 가드를 SPRT·베이즈·신뢰구간 대안과 비교한 베르누이 분석(VI-C절)과, 모델 촉발 질문이 정확도 추정을 얼마나 치우치게 하는지의 측정(VI-D절).
- **C4 (프라이버시).** 더 강한 공격자와 더 작은 후보 집합으로 32개 움직임 특징에 가한 재식별 공격, 그리고 단말이 내보낼 수 있는 33개 학생 가중치에 대한 공격(VI-E절).
- **C5 (재현성).** 모든 실험은 저장소의 스크립트다. 이 논문의 모든 수치는 스크립트가 만들었고 그 출력 파일을 수치 옆에 적었으며, 시뮬레이터의 학습 규칙은 LiteRT 모델의 확률과 일치하는지 검사한다.

II. 관련 연구

A. 모바일 단말의 온디바이스·지속 학습

추론만이 아니라 학습까지 폰에서 하는 일은 주류 도구에서 실용화되었다. TensorFlow Lite(현 LiteRT)는 TensorFlow 2.7에서 온디바이스 학습을 추가해 하나의 모델 파일에 학습·추론 시그니처를 따로 두고 체크포인트로 가중치를 보존해, 매 갱신이 이전 상태에서 이어지게 했다 [1]. 메모리가 제한된 학습 연구는 역전파 비용을 파라미터 수가 아니라 활성값 메모리가 좌우하므로 적은 파라미터만 갱신하는 데 집중했다. TinyTL은 가중치를 고정하고 편향과 가벼운 잔차 모듈만 학습해 학습 메모리를 최대 6.5× 줄였고 [2], LifeLearner는 메타학습·리허설·압축을 결합해 임베디드 플랫폼에서 178.7×의 메모리 절감으로 오라클과 몇 점 차 안에서 지속 학습을 돌렸다 [3]. 연합 학습은 원시 데이터를 단말에 두고 이런 지역 갱신의 집계를 서버로 옮기며 [4], 하나의 전역 모델이 이질적인 클라이언트에 잘 맞지 않는다는 점을 다룬 많은 후속 연구가 모델 일부를 클라이언트별로 두는 개인화 연합 변형을 제안했다 [5]. 정서 감지에서는 Meegahapola 등이 여덟 나라에 걸쳐 학습한 기분 모델이 일반화가 나쁘고 나라별 또는 부분 개인화 모델이 가장 좋았음을 보여 [6] 지역 적응의 동기가 된다. 이 문헌은 라벨된 예가 단말에 도착한다고 가정한다. 우리 설정에서는 갱신 신호가 다른 센서에서 온 잡음 섞인 대리 신호이고 모델은 33 파라미터 로지스틱 회귀이므로, 문제는 학습이 메모리에 들어가는지가 아니라 신호가 도움이 될 만큼 좋은지다.

B. 정서 추정을 위한 모바일 센싱

수동 스마트폰·웨어러블 센싱은 십여 년 동안 현장 경험 표집(ESM)과 짝지어 순간 정서를 추정하는 데 쓰였다. K-EmoPhone은 77명 참가자, 일주일, 5,582개의 ESM 응답에 정서가·각성·스트레스·주의 라벨을 폰 맥락과 웨어러블 생리 신호와 정렬해 제공하고 [7], 후속인 EmoPhone은 설계를 세 해의 연간 파동으로 확장해 최선의 방법이 사용자 안·사용자 간·파동 간 예측 중 어느 것인지에 따라 다름을 보였다 [8]. 움직임만 입력으로 써도 정서 정보가 있다. Wampfler 등은 82명 사용자가 열 주 동안 타이핑하는 중 기록한 관성 신호로 정서가 AUC 0.83에 도달했고 개인화 모델이 몇 점을 더했으며 [9], Woll 등은 259명의 64 Hz 가속도 신호로 순간 기분을 예측해 엉덩이에서 약 0.38의 R^2를, 손목에서 가장 약한 결과를 얻었다 [10]. Taylor 등은 각 사람을 다중 과제 모델의 한 과제로 다루어 다음 날 기분에서 단일 모집단 모델보다 큰 이득을 보고했고 [11], Meegahapola 등은 나라 간에서 같은 순서를 보고했다 [6]. Fisher 등은 집단 수준의 연관이 집단 안의 개인을 설명하지 못하는 일이 잦음을 보여, 사용자 간 정확도와 사용자 안 정확도는 다른 양이며 따로 보고해야 함을 밝혔다 [12]. 우리는 두 값을 전편에서 함께 보고한다. 위의 개인화 이득은 서버 측 재학습, 자기보고 라벨, 수 주에서 수 개월의 데이터로 얻은 것이다. 대리 라벨, 온디바이스 학습, 약 일주일의 데이터에서도 그 이득이 남는지는 측정된 바 없으며, 우리의 K-EmoPhone 재생은 이에 답하도록 설계되었다.

C. 자기 학습, 교차 모달 교사–학생 학습, 잡음 라벨

한 모달리티로 다른 모달리티를 감독하는 일은 잘 확립되어 있다. Albanie 등은 라벨 없는 영상으로 표정 네트워크를 음성 감정 모델에 증류했고, 학생이 교사와 완전 지도 학습 아래에 머물렀다고 보고했다 [13]. 센서 영역에서 Ni 등은 영상 행동 인식 교사를 시험 때 센서만으로 도는 가속도계 학생에 증류했고 [14], Tang 등은 관성 데이터에서 교사–학생 자기 학습과 자기 지도를 결합해 최대 12점의 F1 이득과 열 배 적은 라벨로의 동등 성능을 보고했다 [15]. 우리 구성에 가장 가까운 Onim 등은 노인 40명의 웨어러블 생리 회귀 모델에 iMotions 표정 분석을 정답으로 써서 카메라가 학습 때만 필요하게 했다 [16]. 현장의 준지도 스트레스 감지도 같은 라벨 부족을 다루고 [17], Noisy Student는 잡음을 의도적으로 넣고 학생이 교사보다 많은 데이터를 볼 때 자기 학습이 학생을 개선할 수 있음을 보였다 [18]. 공동 학습(co-training)은 같은 목표의 조건부 독립인 두 뷰가 서로를 끌어올릴 수 있는 이유를 형식화하는데 [19], 얼굴과 움직임 특징은 정서의 그런 두 뷰여서 이 설계를 뒷받침하지만 각 뷰가 개별적으로 정보적이어야 한다. 잡음 라벨 학습 문헌이 조건을 정한다. 분류 잡음 모델에서는 뒤집힘 비율이 절반 아래이면 학습이 가능하고 표본 복잡도는 $1/(1-2\eta)^2$로 커지며 [20], 개관 논문들은 라벨 잡음이 분류기를 어떻게 망가뜨리고 어떤 방법이 강건한지 정리한다 [21]. 따라서 정확도 p의 교사는 $(2p-1)$에 비례하는 정보를 더하고, 주어진 양의 참 라벨에 맞먹기 위한 의사 라벨 밀도 d는 p가 0.5에 가까워질수록 급격히 커진다. 선행 교차 모달 연구는 하나의 동작점만 보고했지만, 우리는 교사 정확도 p와 밀도 d를 통제 변수로 다루어 자기 학습이 도움이 되는 영역을 지도로 그린다.

D. 개인화, ESM 부담, 촉발 질문의 선택 편향

조밀한 자기보고는 개인화의 직접적인 길이지만 비용이 있다. 모바일 ESM 개관은 신호·사건·간격 조건부 질문의 설계 공간과 라벨 밀도 대 참가자 부담의 상충을 정리한다 [22]. Eisele 등은 질문 빈도보다 설문 길이가 체감 부담과 부주의 응답을 높인다는 것을 실험으로 보였고 [23], Reiter와 Schoedel은 592명에서 무응답이 과거 순응도와 맥락으로 예측된다는 것, 즉 무작위 질문에서도 결측이 무작위가 아님을 밝혔다 [24]. 질문이 센서나 모델로 촉발될 때 더 특수한 문제가 생긴다. Lathia 등은 맥락 불협화라 부른 현상을 정량화했다. 센서 촉발 ESM은 무작위 표집에 비해 표집된 행동의 분포를 바꾸고, 그 편향은 촉발 설계에 달려 있다 [25]. 정보적이라 판단한 순간에 질문을 촉발하고 그 응답으로 평가되는 모델은 그 편향을 물려받는다. 표준 처방은 관측을 표집 확률의 역수로 재가중하는 역확률 가중 [26]과, 적시 개입을 위한 미세 무작위 시험처럼 표집 시각 자체를 무작위화하는 것이다 [27]. 우리는 평가에 둘째 길(응답이 유일한 정답인 무작위 시각 군)을 택하고, 모델 촉발 응답이 무작위 시각 분포에서 얼마나 벗어나는지 정량화하는 데 첫째 길을 쓴다.

E. 움직임 특징과 모델 파라미터의 프라이버시

가속도계 데이터는 익명이 아니다. Na 등은 보호 건강 정보를 제거한 뒤에도 20분 집계 가속도 데이터로 국가 활동 데이터셋의 성인과 아동 85% 이상을 재식별했고 [28], Neverova 등은 1,500명 사용자의 폰 움직임 패턴에서 사용자 신원을 학습했으며 [29], Kröger 등은 가속도 스트림에서 가능한 위치·활동부터 신원·건강까지의 추론 범위를 개관한다 [30]. Malekzadeh 등은 온디바이스 변환으로 활동 인식을 92% 이상 유지하면서 신원 인식을 7% 아래로 낮췄다 [31]. 둘째 채널은 모델 자체다. 멤버십 추론은 모델 출력에서 어떤 기록이 학습 집합에 있었는지 복원하고 [32], 협력 학습의 기울기나 파라미터 갱신은 과제와 무관한 참가자 데이터의 속성을 누출하며 [33], 차등 프라이버시 SGD는 유용성을 대가로 이 누출을 제한하고 [34], 정서 인식에서는 다중 과제 차

등 프라이버시 연합 설계로 신원 누출과 스트레스 정확도를 맞바꾼 예가 있다 [35]. 데이터를 올리지 않는 온디바이스 시스템에서 남는 채널은 백업이나 진단으로 단말을 떠날 수 있는 33개 파라미터다. 선행 연구는 특징을 익명화하거나 모델을 보호하는 한쪽만 했지만, 우리는 같은 요약 특징과 매시간 갱신되는 가중치에 대해 둘 모두를 측정한다.

III. 문제 설정과 표기

사용자 u는 분 단위 움직임 요약 $x_t \in \mathbb{R}^{32}$(16개 분 단위 특징의 지난 30분 중앙값과 사분위 범위, IV-A절)의 흐름을 만든다. 정답은 무작위 스케줄러(B군)가 뽑은 시각 s의 간헐적 자기보고 $y_s \in \{0,1\}$(중립 위의 각성; 중립 위의 정서가)이다. 모집단 모델 f_0은 다른 사용자들로 학습된다. 학생 g_θ는 표준화한 x_t 위의 33 파라미터 로지스틱 모델로, 모집단 로지스틱 시드 θ_0에서 초기화된다. 교사는 분의 일부에 밀도 d(라벨된 분의 비율)와 정확도 $p = \Pr(\tilde{y}_t = y_t)$로 의사 라벨 $\tilde{y}_t$를 주며, 클래스 의존 편향 b가 있을 수 있다. 단말은 가장 최근의 교사 라벨 2,000분에 대해 전체 배치 기울기 100스텝으로 θ를 매시간 갱신한다.

평가는 개인화 아래에서 다르게 움직이는 두 가지 정확도 관점을 쓴다. **전체 AUROC**는 모든 사용자의 모든 프로브를 함께 순위 매기므로 각 사용자의 '수준'을 맞히는 것을 보상한다. **사용자 안 AUROC**는 사용자별로 계산해 평균하며 '한 사람 안의 변화'를 추적하는 것을 보상한다. 수준은 라벨 몇 개로 배울 수 있지만 변화 추적은 그렇지 않다. 우리는 두 값을 전편에서 보고하고 사용자 안 AUROC를 주 지표로 삼는다(어떤 시뮬레이션도 돌리기 전에 `docs/PREREG.md`에 사전등록).

IV. 시스템 설계

A. 움직임 특징과 모집단 모델

폰은 OS가 주는 속도(시험 단말에서 약 50 Hz)로 가속도계를 표집해 8 Hz 격자로 보간하고 2 Hz로 블록 평균하는데, 이 속도에서 공개 데이터셋과 단말이 정확히 일치한다(`src/s6_build_2hz.py`, `Features.java`). 매분 중력을 제거한 크기 신호에서 방향 무관 특징 16개를 얻는다(분포 통계 다섯, 지배 주파수, 스펙트럼 엔트로피, 0.1~1 Hz 대역 전력, 저크 통계 다섯, 초당 강도의 평균과 변동계수, 정지 비율). 30분 요약은 각 특징의 중앙값과 IQR로 32개 값이다. 모집단 모델은 잎 3개짜리 트리 50개의 LightGBM 분류기로, K-EmoPhone(V-A절)에서 학습해 단말용 7.5 KB 표로 평탄화했다. VI-A절은 같은 특징 위의 33 파라미터 로지스틱 모델이 이와 통계적으로 구분되지 않음을 보이며, 학생이 그만큼 작을 수 있는 이유다.

B. 교사: 화면 사용 중 얼굴 블렌드셰이프

화면이 켜져 있고 사용자가 폰을 들고 있을 때 전면 카메라는 MediaPipe Face Landmarker를 초당 2프레임으로 돌려 52개 블렌드셰이프 계수만 남기고, 영상은 저장하지 않는다. 앱은 매분 평균 미소 계수(`mouthSmileLeft`와 `mouthSmileRight`의 평균), 평균 `jawOpen`, 얼굴이 검출된 프레임 비율을 집계한다. 교사는 얼굴 검출률이 0.3 이상일 때 미소가 θ_v를 넘으면 정서가 의사 라벨을, 미소와 턱의 합이 θ_a를 넘으면 각성 의사 라벨을 낸다. 임계값은 첫 며칠 계수의 70번째 백분위수로 사용자별로 정하거나, 무작위 프로브 답이 20개 이상 쌓이면 그 답과의 일치를 최대화해 정한다(`src/s8_teacher.py`). 이 규칙은 의도적으로 단순하며, 공개 데이터로 타당성을 가장 덜 확인할 수 있는 구성 요소다(VII절).

C. 학생과 온디바이스 학습

학생은 $g_\theta(x) = \sigma(w^\top z + b)$, $z = (x - \mu)/s$이며 μ, s는 모델에 저장된 모집단 통계다. `infer`와 `train` 시그니처를 가진 LiteRT 모델로 내보낸다. 자동 미분이 LiteRT 내장 연산자가 아닌 연산자(`BroadcastGradientArgs`)를 만들었기 때문에 기울기는 닫힌 형태로 쓴다: $\nabla_w = Z^\top(\sigma(Zw+b)-y)/n$, $\nabla_b = \mathbf{1}^\top(\sigma(Zw+b)-y)/n$, 학습률 0.05. 체크포인트 연산자는 Flex 델리게이트가 필요하므로 가중치는 `get_weights`/`set_weights` 시그니처로 읽고 쓴다. 학습기는 가장 최근의 교사 라벨 2,000분을 보관하고, 50분 이상 있을 때 한 시간에 한 번 100스텝을 돈다(`OnDeviceTrainer.java`). 시뮬레이터가 쓰는 numpy 재구현은 고정 프로브 배치에서 LiteRT 확률을 10^{-4} 이내로 재현한다(`tests/test_loop_sim.py`).

D. 접촉 게이트

단말이 충전 중이거나, 화면이 꺼져 있고 직전 분의 정지 비율이 0.9를 넘으면 추정은 중단되지만 기록은 계속된다(`ContactGate.java`). K-EmoPhone에서 같은 규칙은 창의 18.3 %를 중단시키며, 중단된 창의 각성 AUROC는 더 낮지만(0.595 대 0.623) 차이의 참가자 부트스트랩 신뢰구간은 영을 포함한다(+0.028 [−0.021, 0.080]).

E. 두 군 질문과 성능 가드

A군은 현재 각성 추정이 직전 질문 때의 추정과 0.25 이상 다르고 30분 이상 지났을 때 질문한다. B군은 09:00에서 23:00 사이의 균일 무작위 시각에 하루 세 번, 30분 이상 간격으로 질문한다. 평가와 가드에는 B군 답만 쓴다. 가드는 모든 B군 답에서 모집단 모델과 학생을 채점하고(임계 0.5), 14일 창을 유지하며, $n \geq 15$가 되면 학생의 정확도가 모집단 모델보다 0.10 넘게 낮을 때 모집단 모델로 되돌리고, 0.05 이상 높아지면 학생을 다시 켠다(`DriftGuard.java`). VI-C절이 이 상수들을 평가한다.

F. 구현

표 1에 구현의 단말, 런타임, 모델 파일, 테스트를 적었다.

표 1. 온디바이스 루프의 구현. 출처: `docs/REPO_MAP.md`, `results/S8_NOTES.md`.

항목	선택
단말	Samsung Galaxy Note9 (SM-N960N), Android 10; 앱 targetSdk 29, minSdk 26, arm64
런타임	LiteRT (org.tensorflow:tensorflow-lite 2.16.1), MediaPipe tasks-vision 0.10.35, CameraX 1.4.2
학습 측 도구	Python 3.11.9, LightGBM 4.7.0, scikit-learn 1.8.0, TensorFlow 2.19.0 (모델 내보내기만)
모델 파일	모집단 모델 7.5 KB 평탄화 트리; 학생 `head.tflite` 9.4 KB; 시드 가중치 2.5 KB 텍스트
APK	22.5 MB (MediaPipe·LiteRT 포함); INTERNET 권한 없음
테스트	pytest 13개(특징·라벨 파이프라인, 골든 로그 재생) + JUnit 31개(스케줄러, 가드, 접촉 게이트, 학생 일치) + 시뮬레이터 테스트 2개

V. 평가 방법

A. 데이터

K-EmoPhone [7]은 약 일주일에 걸친 참가자 77명과 5,582개의 ESM 응답을 담고 있다. 그중 3,771개는 직전 30분의 손목 가속도 커버리지가 50 % 이상이고 완전한 분이 다섯 이상이어서 우리의 응답 집합이 된다(`data/processed/kemophone_2hz_block.parquet`; 여기서 다음을 계산: 사용자당 응답 10~101개, 중앙값 49; 기간 1.4~6.5일, 중앙값 6.3). 각성과 정서가는 영을 중심으로 한 척도로 보고되며, 영에서 이진화하고(영 초과를 양성; 양성 비율 각성 38.8 %, 정서가 58.0 %) 사용자 중앙값 대안을 VI-A절에서 시험한다. 가속도계는 약 8 Hz의 손목 밴드이며 폰 자체의 센서가 아니다. 데이터셋은 폰 IMU 데이터를 공개하지 않는다. 따라서 이 논문의 모든 움직임 결과는 폰이 동일하게 계산하는 손목 움직임 특징에 대한 결과이며, 폰에 담긴 움직임으로의 전이는 VII절에서 다시 다루는 한계다.

B. 루프 시뮬레이터

각 사용자를 시간 순으로 재생한다(`experiments/loop_sim/sim.py`; 설계와 가정은 `docs/LOOP_SIM_README.md`). 모든 응답에 대해 직전 30개 분 각각에서 폰과 똑같이 30분 요약을 계산한다. 응답 시각의 요약은 모집단 모델의 입력과 마지막 자리까지 같다(`experiments/loop_sim/build_minutes.py`, 최대 |차이| = 0). 교사는 이 분들 각각에 응답 자신의 라벨을 확률 $1-p$로 뒤집어 확률 d로 붙인다. 편향 b는 평균 뒤집힘 비율을 유지하면서 음성의 뒤집힘을 양성보다 더 잦게 만든다. 학생은 사용자 기간의 매 정시에 갱신되며, 단말과 같이 새 분이 왔든 안 왔든 한 시간에 100스텝을 돈다. 엿새 기간이면 라벨이 약 49개 응답을 복사한, 강하게 상관된 최대 2,000분에 대해 약 14,000스텝을 도는 셈이다. 응답에 대한 예측은 그 응답의 교사 분들이 추가되기 전에 이루어지므로 라벨 정보가 앞으로 새지 않는다. 각 사용자 기간의 앞 60 %는 학습 구간이고 뒤 40 %의 응답이 평가 집합이다(사용자당 최소 10개; 각성 65명, 정서가 59명). 조건: (a) 모집단 모델; (b) 같은 학습기로 이전 ESM 답에 미세 조정한 시드; (b′) 이전 ESM 답의 L2 로지스틱; (c) 사용자별 Platt 보정을 더한 모집단 모델; (d) 교사 라벨의 학생; (d′) 시드 쪽으로 L2 앵커를 둔 학생($\lambda \in \{0.1, 0.3, 1\}$); (d″) 가중치를 시드에 고정하고 절편만 갱신; (e) 단말처럼 꺼진 상태로 시작하는 가드를 단 학생; (f) 오라클 교사(p=1, d=1); 그리고 참조로 손대지 않은 시드. 격자: $p \in \{0.6,0.7,0.8,0.9\}$, $d \in \{0.2,0.5\}$, $b \in \{0,0.2\}$, 시드 셋, 51셀. 시뮬레이터는 응답 사이의 정서 상태를 만들어내지 못한다. 분리해 내는 것은 같은 바탕 정보에서 라벨 잡음·밀도·온디바이스 학습 규칙의 효과다.

C. 통계

사용자 안 AUROC는 평가 응답이 10개(시뮬레이터) 또는 20개(벤치마크) 이상이고 두 클래스를 모두 가진 사용자들에 대해 평균한다. 신뢰구간은 참가자 부트스트랩(사용자 1,000회 재표집)이고, 짝 비교는 효과 크기 $r = Z/\sqrt{n}$의 Wilcoxon 부호 순위 검정을 쓴다. AUPRC, 0.5에서의 MCC, Brier 점수, 기대 보정 오차도 보고한다(`experiments/common/eval.py`). 가드 분석은 조건당 10,000회의 베르누이 시뮬레이션이다(`experiments/guard_sim/guard_sim.py`).

VI. 결과

A. 모집단 모델과 절제 실험 (RQ1)

표 2는 피험자 하나 제외(leave-one-subject-out) 평가에서 모집단 모델을 기준선들과 비교한다. 움직임 특징은 운영체제의 활동 범주를 각성에서 사용자 안 AUROC 0.055(95 % CI 0.027~0.081, Wilcoxon $p = 4 \times 10^{-5}$), 정서가에서 0.056(0.024~0.094, $p = 0.002$) 앞서며, 이는 그 기준선에 대한 가설 H1a를 확인한다. 이 비교는 특징이 기여하는 바의 한계도 정한다. 손목 신호를 초당 세 범주(정지, 가벼움, 걷기)로 뭉개고 그것을 요약하면 32개 특징과 같은 사용자 안 AUROC가 나온다(각성 0.636 대 0.623, 차이 +0.013 [−0.003, 0.033]). 세 특징군(크기, 급격함, 정지) 중 어느 하나만으로도 전체 집합과 같고, 33 파라미터 L2 로지스틱 모델은 LightGBM과 같으며(−0.005 [−0.020, 0.008]), 16 유닛 MLP는 더 나쁘다(−0.035 [−0.056, −0.016]). 시각만으로는 우연 수준(0.526)이고 움직임 모델에 더해도 아무것도 보태지 않는다. 각 사용자의 수준만 담는 사용자별 상수 평균 라벨은 전체 AUROC 각성 0.731, 정서가 0.778에 도달해 움직임 모델의 0.623과 0.587을 훨씬 넘는데, 이것이 전체 AUROC가 개인화의 잘못된 주 지표인 이유를 보여준다. 영 대신 사용자 중앙값으로 이진화하면 사용자 안 AUROC는 0.01 미만으로 바뀐다.

표 2. 사용자 안 AUROC(응답 ≥ 20인 72 / 71명 사용자의 평균), 참가자 부트스트랩 CI. 출처: `results/benchmark/summary.csv`.

모델	각성 사용자 안 [95 % CI]	Δ 대 움직임	정서가 사용자 안	Δ 대 움직임
움직임 32특징, LightGBM 50×3	0.623 [0.594, 0.650]	–	0.597 [0.562, 0.628]	–
OS 활동 범주	0.567 [0.541, 0.594]	−0.055 [−0.081, −0.027]	0.540 [0.505, 0.573]	−0.056 [−0.094, −0.024]
손목 3범주 coarse	0.636 [0.609, 0.660]	+0.013 [−0.003, +0.033]	0.592 [0.557, 0.625]	−0.005 [−0.019, +0.010]
시각(hour)	0.526 [0.496, 0.555]	−0.097 [−0.130, −0.064]	0.520 [0.489, 0.551]	−0.076 [−0.118, −0.036]
움직임, 로지스틱(33 파라미터)	0.617 [0.582, 0.648]	−0.005 [−0.020, +0.008]	0.586 [0.549, 0.620]	−0.010 [−0.027, +0.006]
움직임, MLP(은닉 16)	0.587 [0.562, 0.611]	−0.035 [−0.056, −0.016]	0.565 [0.531, 0.594]	−0.032 [−0.061, −0.004]

창 길이(H1b, 그림 1): 1분 요약은 각성에서 30분보다 나쁘고(−0.027 [−0.050, −0.005]) 5~10분 요약은 정서가에서 나쁘며(5분에서 −0.060 [−0.092, −0.026]), 15·30·60분은 구분되지 않는다. 따라서 30분은 최적이 아니라 안전한 선택이며, 60분이 정확도를 떨어뜨린다는 이전 주장은 신뢰구간으로 뒷받침되지 않는다.

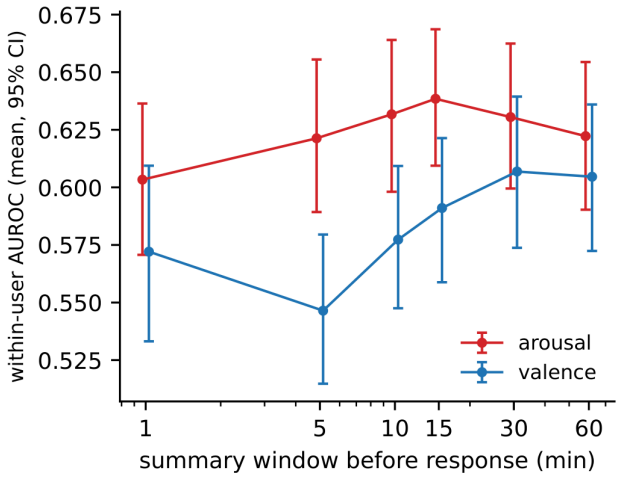


그림 1. 요약 창 길이와 모집단 모델의 사용자 안 AUROC(사용자 평균, 참가자 부트스트랩 95 % CI; K-EmoPhone에서 피험자 하나 제외). 각성에서 1분은 30분보다 나쁘고 정서가에서 5~10분이 나쁘며, 15·30·60분은 구분되지 않는다. 출처: results/benchmark/summary.csv.

B. 조밀한 잡음 교사 대 희소한 정확 라벨 (RQ2)

그림 2는 사전등록 비교를 지도로 그린다. 자기 학습 학생(조밀, 잡음)과 이전 ESM 답에 미세 조정한 시드(희소, 정확)의 사용자 안 AUROC 차이를 (p, d) 격자 위에 그린 것이다. 어떤 교사 정확도 p^* 위에서는 학생이 이긴다는 가설 H2는 지지되지 않는다. 시드 셋 평균 차이는 32개 셀 전부에서 영 이하이고(각성 −0.001~−0.023, 정서가 −0.009~−0.064), 유의하게 양인 셀은 없으며(각성의 신뢰 상한이 +0.08까지 가므로 동등성도 보이지 못한다), 낮은 정확도·밀도의 정서가 셀 넷($p \le 0.7$, $d = 0.2$)은 seed-0 부트스트랩 구간이 음의 쪽에서 영을 제외하지만 32개 검정에 대한 Holm 보정을 넘기는 것은 없다. 더 강한 진술은 조건 없이 성립한다. 모든 각성 셀에서 학생은 신뢰 상한 −0.016 이하로 모집단 모델 아래다. 학생의 사용자 안 AUROC는 p에 거의 무감하고($p = 0.6$에서 0.9까지 각성 0.51~0.54) 각성에서는 낮은 밀도가 약간 낫다(정서가는 반대). 이는 이미 라벨 잡음이 결정적 제약이 아님을 시사한다.

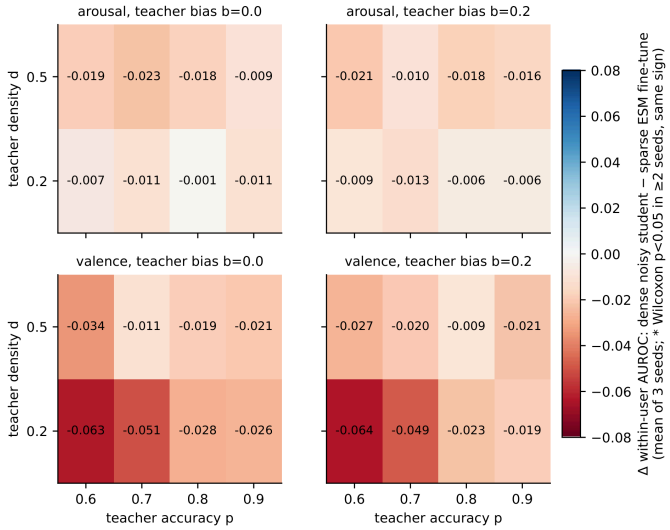


그림 2. 사전등록 비교(H2): 교사 정확도 p와 밀도 d에 대한, 자기 학습 학생(조밀한 잡음 교사)과 이전 ESM 답에 미세 조정한 시드(희소, 정확)의 사용자 안 AUROC 차이. 편향 b = 0과 b = 0.2(시드 셋 평균). 양인 셀은 없다. 출처: results/loop_sim/summary.csv.

잡음 없는 라벨 복사 교사인 오라클 조건이 이 제약을 명시적으로 드러낸다(표 3과 그림 3). 모든 분에 완벽한 라벨이 있어도 학생은 사용자 안 AUROC 0.514(각성)와 0.567(정서가)에 머물러, 모집단 모델(0.638, 0.627)과 손대지 않은 자기 시드(0.626, 0.606) 아래다. 같은 학습기의 ESM 미세 조정은 0.536과 0.579, 정규화한 ESM 로지스틱은 0.582와 0.578, 사용자별 Platt 보정은 0.537과 0.527이다(일부 사용자는 열 개 라벨에서 기울기가 음수로 추정된다). 우리가 시험한 모든 온디바이스 갱신은 사용자 안 판별을 낮추고, 손실은 학습이 시작되는 둘째 날에 나타나 그 주 안에 회복되지 않는다(그림 4). 같은 조건에서 전체 AUROC는 각성 0.617에서 0.634~0.732로, 정서가 0.586에서 0.668~0.768로 오른다. 학생이 사용자의 수준을 배워 그 사용자의 확률을 한 덩어리로 올리거나 내리면 사용자 간 순위는 좋아지지만 사용자 안 순위는 좋아지지 않는다. 가중치를 L2 벌점으로 시드에 묶으면 손실이 절반이 되지만(각성에서 $\lambda = 0.3$일 때 −0.118에서

−0.057로; 세 λ 모두 같은 그림) 없어지지는 않는다. 가중치를 시드에 고정하고 절편만 갱신하는, 만들 수 있는 가장 보수적인 학습기도 사용자 안 AUROC를 낮추면서(각성 0.603, −0.034 [−0.056, −0.012]; 정서가 0.588) 전체 AUROC를 0.714 / 0.760으로 올린다. 매시간 변하는 수준 보정이 한 사용자 자신의 응답의 시간 순서를 바꾸기 때문에, 수준조차 천천히 적용하거나 순위에서 빼야 한다. 학생을 꺼진 상태로 시작해 최근 프로브에서 0.05 앞설 때 켜는 가드는 평가 응답의 52~60 %에서 학생을 활성 상태로 두고 사용자당 0.6~0.7회 전환하며, 역시 손실을 절반으로 줄인다(각성 −0.059, 정서가 −0.041 [−0.091, +0.007]).

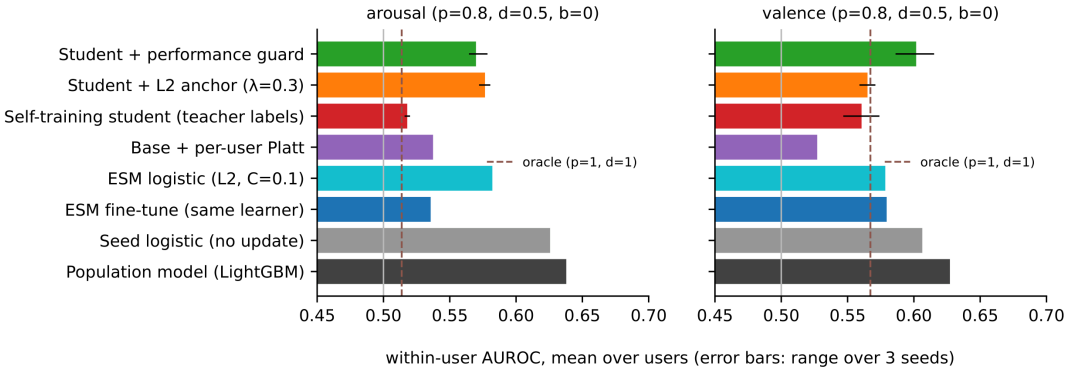


그림 3. p = 0.8, d = 0.5, b = 0에서 조건별 사용자 안 AUROC(사용자 평균; 오차 막대: 시드 셋의 범위; 점선: p = 1, d = 1의 오라클 학생). 갱신된 모든 모델이 모집단 모델과 손대지 않은 시드 아래다. 출처: results/loop_sim/summary.csv.

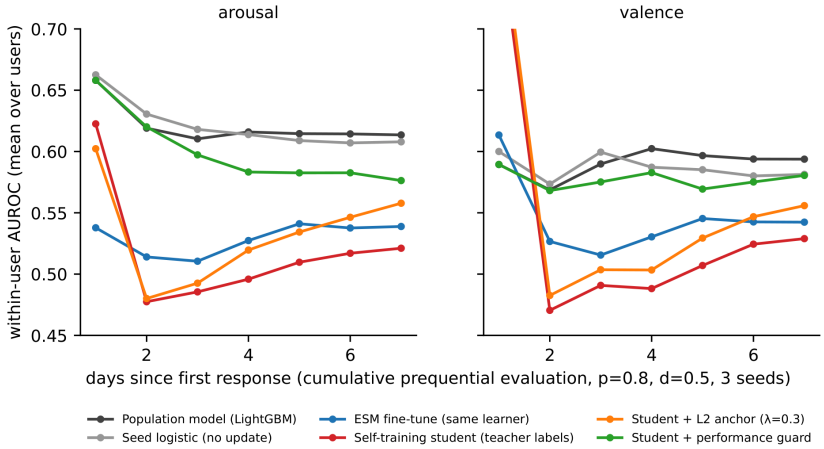


그림 4. 각 사용자의 첫 응답 이후 날짜별 누적 prequential 사용자 안 AUROC(p = 0.8, d = 0.5, 시드 셋). 갱신 모델은 학습이 시작되는 2일째에 떨어지고 그 주 안에 회복되지 않는다. 출처: results/loop_sim/preds_*.parquet.

표 3. $p = 0.8$, $d = 0.5$, $b = 0$에서의 루프 시뮬레이터(사용자 안·전체 값은 시드 셋 평균; CI는 seed 0; 65 / 59명). 모집단 모델의 0.638이 표 2의 0.623과 다른 것은 각 사용자 응답의 뒤 40 %에서 10응답 필터로 채점했기 때문이다. 어떤 갱신 조건에서도 사용자의 20 %~37 %는 모집단 모델 위에 있다(열 `frac_users_gt_base`). 출처: `results/loop_sim/summary.csv`.

조건	각성 사용자 안	Δ 대 기본 [95 % CI]	정서가 사용자 안	Δ 대 기본	전체 AUROC (각성/정서가)
모집단 모델(LightGBM, 고정)	0.638	–	0.627	–	0.617 / 0.586
시드 로지스틱, 갱신 없음	0.626	−0.012 [−0.033, +0.006]	0.606	−0.021 [−0.052, +0.008]	0.604 / 0.558
ESM 미세 조정, 같은 학습기	0.536	−0.102 [−0.150, −0.051]	0.579	−0.048 [−0.109, +0.008]	0.634 / 0.672
ESM 로지스틱, L2	0.582	−0.056 [−0.092, −0.015]	0.578	−0.049 [−0.110, +0.013]	0.650 / 0.668
기본 + 사용자별 Platt	0.537	−0.100 [−0.137, −0.063]	0.527	−0.100 [−0.159, −0.036]	0.732 / 0.757
학생, 교사 p=0.8, d=0.5	0.518	−0.118 [−0.173, −0.061]	0.561	−0.080 [−0.138, −0.020]	0.647 / 0.703
학생 + L2 앵커 λ=0.3	0.577	−0.057 [−0.098, −0.014]	0.565	−0.068 [−0.115, −0.021]	0.719 / 0.765
학생 + 가드	0.570	−0.059 [−0.104, −0.016]	0.602	−0.041 [−0.091, +0.007]	0.662 / 0.715
학생, 절편만 갱신	0.603	−0.034 [−0.056, −0.012]	0.588	−0.039 [−0.068, −0.012]	0.714 / 0.760
오라클 학생(p=1, d=1)	0.514	−0.124 [−0.177, −0.071]	0.567	−0.060 [−0.113, −0.008]	0.655 / 0.718

시뮬레이터가 말할 수 있는 것과 없는 것. 교사의 라벨이 응답 라벨에서 파생되므로 조밀한 신호는 희소한 신호에 없는 정보를 담지 않는다. 따라서 시뮬레이터는 '같은 정보량에서' 잡음과 밀도의 상충, 그리고 학습 규칙의 행동을 시험하

는 것이고, 표정이 응답 사이의 정서 상태를 담을 가능성을 시험하는 것이 아니다. 그 범위 안에서 결과는 분명하다. K-EmoPhone의 분량(사용자당 약 49개 응답과 650 교사 분)에서는 정규화 없는 매시간 갱신이 사용자의 수준에 과적합하며, 더 좋은 교사가 이를 고치지 못한다. VII절이 설계상의 결론을 끌어낸다.

C. 가드의 행동 (RQ3)

표 4와 그림 5는 하루 세 번 무작위 프로브, 기본 정확도 0.60, 정확도가 Δ만큼 다른 학생으로 시뮬레이션한 28일 동안 네 가드의 행동을 보인다(기본 정확도 0.55와 0.65의 결과는 최대 0.02 차이). 학생은 켜진 상태로 시작하는데, 나쁜 학생에게는 최악의 경우다. 단말과 루프 시뮬레이터에서는 꺼진 상태로 시작한다. 두 모델의 오류는 독립으로 뽑는다. 실제로는 오류가 상관될 가능성이 크고, 그러면 모든 가드가 다소 더 강력해진다. 현행 고정 임계 규칙은 0.10 나쁜 학생을 14일 안에 확률 0.76으로, 0.20 나쁜 학생을 0.94로 잡아내며 중앙값 지연은 4.7일이지만, 기본과 정확히 같은 학생도 14일 안에 48 %(28일 안에 68 %) 되돌리고 $\Delta = 0$에서 한 달에 한 번쯤 전환한다. 베이즈 사후 가드와 짝 CI 가드는 오복귀율을 8~11 %로 줄이지만 검정력 0.25~0.30과 13일의 중앙값 지연이 대가다. 불일치 프로브에 대한 순차 확률비 검정($\alpha = \beta = 0.05$)은 창 안에서 거의 결정을 내리지 못한다. 마흔두 개의 프로브로는 0.10 차이의 정확도를 믿을 만하게 가를 수 없으므로, 선택은 어느 오류를 받아들일 것인가다. 오복귀는 사용자를 모집단 모델로 돌려놓을 뿐이고 VI-B절이 보듯 이 데이터 분량에서는 그것이 더 좋은 모델이므로, 현행 규칙의 비대칭은 되돌리기 방향에서는 옹호할 수 있다. 잡음에 반응하는 것은 재활성화 규칙(+0.05)이며, 더 엄격하거나 베이즈적인 재활성화 기준이 우리가 가장 먼저 바꿀 것이다. 사전 등록 예측은 절반만 맞았다. 0.2 이상의 오복귀는 예측했지만 0.5 아래의 검정력은 예측하지 못했다.

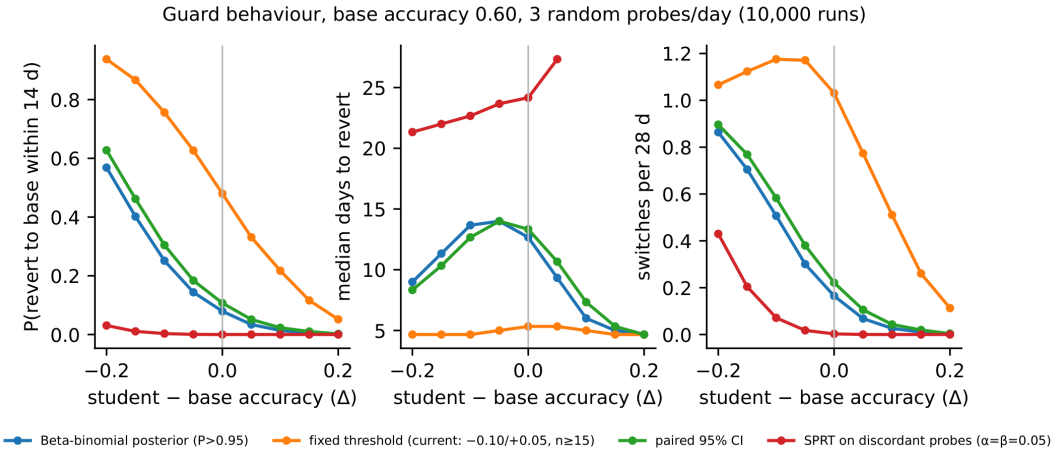


그림 5. 학생–기본 정확도 차이 Δ에 대한 가드의 행동: 14일 안에 모집단 모델로 되돌릴 확률, 되돌리기까지의 중앙값 일수, 28일당 전환 횟수(기본 정확도 0.60, 하루 세 번 무작위 프로브, 10,000회). 출처: results/guard_sim/guard_sim.csv.

표 4. 가드 시뮬레이션, 기본 정확도 0.60, 10,000회. 출처: `results/guard_sim/guard_sim.csv`.

가드	검정력, $\Delta = -0.10$, 14 d	검정력, $\Delta = -0.20$	오복귀, $\Delta = 0$, 14 d	28 d	중앙값 지연	$\Delta = 0$에서 전환 / 28 d
고정 임계(현행)	0.76	0.94	0.48	0.68	4.7 d	1.03
불일치 프로브 SPRT	0.00	0.03	0.00	0.00	22.7 d	0.00
베타-이항 사후($P > 0.95$)	0.25	0.57	0.08	0.15	13.7 d	0.16
짝 95 % CI	0.30	0.63	0.11	0.21	12.7 d	0.22

D. 모델 촉발 질문의 선택 편향 (RQ4)

재생 데이터에서 A군 규칙을 재현한다. 응답 전 매분의 30분 요약에 모집단 모델을 적용하고, 추정이 이전 응답 때의 추정에서 0.25 이상 움직이면 그 응답에 표시한다. 이 규칙은 각성 창의 8.5 %(3,771개 중 322개)와 정서가 창의 2.4 %에서 발화한다. 표시된 응답은 더 극단적이고(평균 $|p - 0.5|$ 0.116 대 0.085, 1.36배), 그 전체 AUROC는 무작위 시각 값과 0.002 이내이며, 사용자 안 추정에 필요한 표시 응답 열 개를 모은 사용자는 네 명뿐이다. 촉발 임계를 0.15로 내리면 창의 삼분의 일에 표시되고 전체 AUROC가 0.022 낮아지며, 75번째 백분위수의 분위수 촉발은 0.030 낮추고 사용자 안 차이는 −0.016 [−0.063, +0.029]이다. 표시된 응답을 각 사용자의 촉발률의 역수로 재가중하면(역확률 가중) 세 촉발에서 전체 AUROC 0.631, 0.603, 0.597로, 가중도 무작위 시각 값을 복구하지 못한다. 명세를 순진하게 읽은 분 단위 변화 규칙은 30분 요약에서는 거의 발화하지 않는다(분 간 변화 중앙값 0.036, 최대 0.26; `results/loop_sim/rq4_selection_consecutive.csv`, `docs/ASSUMPTIONS.md` A8). 따라서 모델 촉발 질문은 촉발 정의에 따라 편향의 부호가 바뀌는 치우친 작은 표본을 만들며, 그 위에서 평가하거나 가드하는 것은 믿을 수 없다. 이것이 무작위 군의 근거다(그림 6).

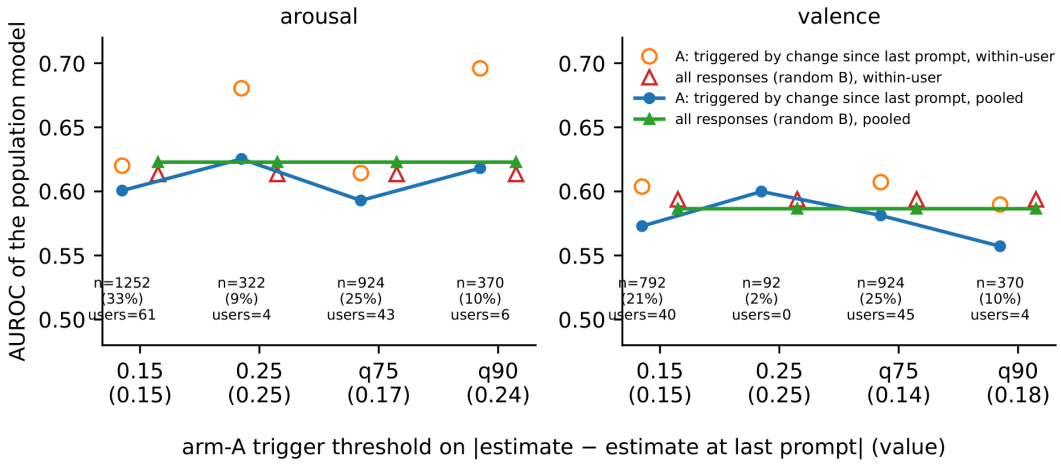


그림 6. 모델 촉발 질문(A군)의 선택 편향: 네 촉발 임계(괄호 안 값)에 대해, A군 규칙이 표시한 응답과 전체 응답에서 모집단 모델의 전체·사용자 안 AUROC. n, 표시 비율, 표시 응답 열 개 이상인 사용자 수를 적었다. 출처: results/loop_sim/rq4_selection.csv.

E. 프라이버시 (RQ6)

특징 재식별. 단일 30분 창의 32개 요약 특징과 시간순 분할에서, 로지스틱 공격자는 77명 가운데 사용자를 top-1 정확도 0.070(우연의 5.4배), top-5 0.193으로 식별하고, 열 개 창의 다수결은 0.186에 이른다. 비선형 공격자가 더 낫지는 않으므로(kNN 0.027, LightGBM 0.052) 식별 정보는 특징 수준의 작은 선형 성분이다. 절대 위험은 작은 후보 집합에서 커진다. 20명 가운데서는 top-1 0.167, 10명 가운데서는 0.224와 top-5 0.719다. 특징을 소수 첫째 자리로 반올림하면 77명 기준 비율이 0.052(우연의 4.0배)로 줄고 측정 가능한 정확도 비용은 없는 반면(사용자 안 AUROC 각성 −0.001 [−0.009, +0.006], 정서가 −0.010 [−0.023, +0.004]), 정수로 반올림하면 0.037(우연의 2.8배)에 이르지만 정확도가 0.55와 0.52로 붕괴한다(`results/privacy/quant_cost.csv`).

가중치 누출. 33개 학생 가중치는 특징보다 훨씬 강한 식별자다. 시뮬레이터 시드 둘로 각 사용자의 가중치를 등록하고 셋째 시드로 질의하면(시드는 교사의 무작위 뒤집힘만 다르다) 최근접 이웃 매칭이 top-1 0.818(우연의 63배), top-5 0.961로 사용자를 식별한다. 공유된 시드 성분을 제거해도 비율은 그대로이고, 앵커를 둔 학생은 라벨 잡음에 덜 흔들리므로 더 잘 식별된다(0.987). 비율을 절반(0.416)으로 낮추려면 가중치와 같은 표준편차의 가우스 잡음이 필요하다. 따라서 집계나 연합 학습을 위해 학생 가중치를 내보내는 설계는 특징보다 훨씬 쉽게 신원을 누출한다. 우리 시스템이 가중치를 단말에 두는 이유가 이 결과다.

F. 시스템 비용 (RQ7)

Galaxy Note9에서 프로브(64 표본, 100스텝) 세 번 실행은 학습에 22.7~44.4 ms(스텝당 0.23~0.44 ms), 모델 적재에 2.3~34.8 ms, 추론 여덟 번에 0.6 ms, 추가 메모리 0.9~1.3 MB가 들었고, 확률은 Python 참조와 최대 6.0×10^{-8} 차이로 일치했다. 폰 자체의 330분 로그에서 한 분의 16개 특징과 30분 요약 계산은 중앙값 1.6 ms(95번째 백분위수 2.6 ms)였다. 단일 스레드 LiteRT 인터프리터를 쓰는 PC에서 매시간 갱신은 파라미터와 배치에 대해 예상대로 커진다. 33 파라미터는 배치 64 / 640 / 2,000에서 0.4 / 1.5 / 4.3 ms, 330 파라미터는 1.2 / 10.1 / 46.5 ms, 3,300 파라미터는 10.5 / 140 / 1,472 ms다. Note9은 같은 33 파라미터·64 표본 프로브를 PC 인터프리터보다 60~120배 느리게(22.7~44.4 ms 대 0.4 ms) 돌렸으므로, 우리보다 백 배 큰 모델을 2,000 표본 버퍼 전체로 돌리면 폰에서 시간당 대략 1.5~3분이 든다. 가능하지만 더는 무시할 수 없다. 단말에서 매시간 학습기는 지금까지 프로브 배치에서만 실행되었다. 저자의 이틀 로그에서 교사는 얼굴이 검출된 31분을 만들어 50 표본 최소치에 못 미쳤고, 기록된 모든 `train` 이벤트의 표본 수는 영이었으며, 실제 교사 라벨로 돌아가는 종단 간 루프는 현장 연구에서 확인해야 한다. 카메라 교사의 배터리 비용은 측정하지 않았고(이번 실행 동안 단말 없음; 절차는 `docs/DEVICE_BENCH.md`), 이전의 배치 대 연속 센싱 비교는 전달 센서 속도를 다른 앱이 좌우해 측정 가능한 차이를 찾지 못했다(`results/S12_NOTES.md`).

VII. 논의

온디바이스 자기 학습은 언제 도움이 되는가? 사용자당 일주일과 49개 자기보고에서는, 이 학습기로는, 교사의 정확도가 어떻든 아니다. 시뮬레이터는 세 가지를 차례로 보인다. 첫째, 이 분량에서 개인의 라벨이 더하는 정보는 그 사람의 '수준'이고, 수준은 어떤 갱신 규칙이든 흡수하므로 모든 조건에서 전체 AUROC가 좋아진다. 둘째, 정규화 없는 매시간 전체 배치 갱신은 그 수준에 과적합해 사용자 안 순서를 망가뜨리므로, 오라클 교사에서도 사용자 안 AUROC가 떨어진다. 손대지 않은 시드는 모집단 모델만큼 좋다. 셋째, 우리가 시뮬레이션할 수 있는 교사는 응답 사이에 정보를 더하지 않으므로 라벨 정확도를 아무리 높여도 이를 고치지 못한다. 그러므로 카메라 교사가 도움이 될 조건은 (i) 자기보고에 없는 정보를 담는 교사인데, 이는 표정과 프로브를 함께 수집하는 현장 연구만이 확인할 수 있다. (ii) 순서까지 배우지 않고는 수준을 흡수할 수 없는 학습기, 예컨대 수준 성분을 판별로 믿지 않고 천천히 변하는 보정으로 적용하는 앵커 갱신(표 3은 매시간 절편만 갱신해도 사용자 안 AUROC 0.03이 든다는 것을 보인다). (iii) Taylor 등과 Meegahapola 등은 가졌고 우리는 갖지 못한, 일주일보다 큰 데이터 분량. 첫째는 열린 질문으로, 둘째는 어떤 배포보다 앞서 시뮬레이터로 이제 평가할 수 있는 공학적 변경으로 본다.

수준 대 변화. 응용에서의 실질적 결론은 개인화 모델을 두 출력으로 읽어야 한다는 것이다. 빨리 배우고 보정과 임계값에 유용한 수준, 그리고 모집단 모델에서 물려받으며 사

용자 자신의 라벨로는 오랫동안 좋아지지 않는 개인 내 순서다. 하나의 AUROC만 보고하면 이것이 숨는다. Fisher 등이 다른 근거로 주장하듯 둘을 모두 보고하기를 권한다.

가드. 하루 세 번 무작위 프로브로는 가드가 두 주 안에 0.10 손실을 잡아내는 것과 좋은 학생을 되돌리지 않는 것을 동시에 할 수 없다. 현행 규칙의 비대칭(빠른 되돌리기, 쉬운 재활성화)은 앞 절반에는 맞고 뒤 절반에는 틀렸다.

교사 타당성 (RQ5). 저자 자신의 2일 로그는 360분을 담았고 그중 31분에 얼굴이 검출되었으며 수동 프로브 답은 셋이었는데, 얼굴 검출 분의 다섯 분 이내에 있는 것은 없었다(`results/teacher/teacher_validity_log.txt`). 따라서 표정에서 정서로의 규칙은 검증되지 않은 채다. 이를 검증할 수 있는 공개 얼굴+자기보고 데이터셋(K-EmoCon, Emognition, AMIGOS)은 접근 요청이 필요하며 절차와 함께 `docs/DATASETS.md`에 적었다.

타당성 위협. 폰이 아닌 손목 가속도계; 양극 척도의 단일 이진화(사용자 중앙값 대안에 강건); 시뮬레이터의 라벨 복사 교사; 일주일의 데이터; 2018년 단말; 공개 데이터셋의 한국 학생 참가자. 선택 편향 결과는 촉발 정의에, 가드 결과는 두 모델 오류의 독립성에 의존하며, 실제로는 오류가 상관되어 모든 가드가 다소 더 강력해질 것이다.

VIII. 윤리와 프라이버시

카메라는 화면이 켜져 있고 폰을 들고 있을 때만 초당 2프레임으로 쓰이며 프레임당 52개 블렌드셰이프 계수만 남는다. 어떤 영상도 카메라 파이프라인을 떠나지 않는다. 모든 원시·파생 데이터는 단말에 남고, 앱에는 네트워크 권한이 없으며, 내보내기는 연구자가 손으로 복사한다. VI-E절은 남은 두 위험을 정량화한다. 요약 특징은 77명의 닫힌 집합에서 우연의 5.4배(작은 집단에서는 더)로, 학생 가중치는 우연의 63배로 사용자를 식별하므로 가중치는 결코 내보내지 않는다. 현장 연구 꾸러미(프로토콜, 동의서, 데이터 관리 계획, 사전등록)는 `docs/field_study/`에 있다. 시뮬레이터의 효과 크기로 한 검정력 분석은 사용자별 AUROC 분산이 가정대로 응답 수에 따라 줄어들면(`docs/ASSUMPTIONS.md` A10) 사용자 안 AUROC 차이 0.10을 검출하는 데 넉 주 동안 참가자 18명(Wilcoxon, 검정력 0.8)을, 그 조정 없이는 50명을 요구한다. 차이 0.05라면 67~188명이 필요하다(`results/field/power.csv`). 단말 로그는 전면 앱 패키지와 미디어 제목도 기록하며, 동의서는 이를 선택 항목으로 알린다. 이 연구에서 저자 자신의 로그 외의 인간 대상 데이터는 수집하지 않았다.

IX. 결론

움직임 기반 정서 추정기의 교차 모달 자기 학습을 위한 완전한 온디바이스 루프를 만들고, 재생 시뮬레이터와 사전등록 가설로 그것이 언제 도움이 되는지 물었다. 일주일의 데이터에서는 도움이 되지 않는다. 완벽한 라벨을 쓴 것을 포함한 모든 온디바이스 갱신은 사용자 안 판별을 수준 보정과 맞바꾸고, 전체 정확도에 나타나는 이득은 그 수준이다. 이것은 판결이 아니라 전제 조건이다. 설계자에게 카메라 교사가 무엇을 더해야 하는지(자기보고 사이의 정보), 학습기가 어떻게 바뀌어야 하는지(수준은 보정으로 두고 순서를 보호), 가드에 무작위 프로브가 몇 개 필요한지, 왜 학생의 가중치가 폰에 남아야 하는지를 말해 준다. 다음 단계는 이 저장소에 명세한 현장 연구이며, 그 첫 일은 공개 데이터가 보여줄 수 없는 정보를 표정이 담고 있는지 측정하는 것이다.

참고문헌

1. TensorFlow Lite Team, "On-device training in TensorFlow Lite," TensorFlow Blog, 2021. [Online]. Available: https://blog.tensorflow.org/2021/11/on-device-training-in-tensorflow-lite.html
2. H. Cai, C. Gan, L. Zhu, and S. Han, "TinyTL: Reduce Memory, Not Parameters for Efficient On-Device Learning," in *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020. [Online]. Available: https://proceedings.neurips.cc/paper/2020/hash/81f7acabd411274fcf65ce2070ed568a-Abstract.html
3. Y. D. Kwon, J. Chauhan, H. Jia, S. I. Venieris, and C. Mascolo, "LifeLearner: Hardware-Aware Meta Continual Learning System for Embedded Computing Platforms," in *Proceedings of the 21st ACM Conference on Embedded Networked Sensor Systems (SenSys '23)*, 2023, pp. 138–151, doi: 10.1145/3625687.3625804.
4. H. B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. Agüera y Arcas, "Communication-Efficient Learning of Deep Networks from Decentralized Data," in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2017, pp. 1273–1282. [Online]. Available: https://proceedings.mlr.press/v54/mcmahan17a.html
5. A. Z. Tan, H. Yu, L. Cui, and Q. Yang, "Towards Personalized Federated Learning," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 12, pp. 9587–9603, 2023, doi: 10.1109/TNNLS.2022.3160699.
6. L. Meegahapola et al., "Generalization and Personalization of Mobile Sensing-Based Mood Inference Models: An Analysis of College Students in Eight Countries," *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, vol. 6, no. 4, pp. 176:1–176:32, 2022, doi: 10.1145/3569483.
7. S. Kang et al., "K-EmoPhone: A Mobile and Wearable Dataset with In-Situ Emotion, Stress, and Attention Labels," *Scientific Data*, vol. 10, Art. no. 351, 2023, doi: 10.1038/s41597-023-02248-2.
8. P. Zhang et al., "EmoPhone: A Multi-Wave Dataset for In-the-Wild Mobile and Wearable Affect Sensing," 2026, *arXiv:2609.16581*. [Online]. Available: https://arxiv.org/abs/2609.16581
9. R. Wampfler, S. Klingler, B. Solenthaler, V. R. Schinazi, M. Gross, and C. Holz, "Affective State Prediction from Smartphone Touch and Sensor Data in the Wild," in *Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems*, 2022, pp. 1–14, doi: 10.1145/3491102.3501835.
10. S. Woll, J. Müther, D. Birkenmaier, G. Biri, U. W. Ebner-Priemer, and M. Giurgiu, "Predicting Momentary Mood in Daily Life from Accelerometer Data: Evaluating Single vs. Multiple Sensor Locations Using Machine Learning," *Sensors*, vol. 26, no. 12, Art. no. 3688, 2026, doi: 10.3390/s26123688.
11. S. Taylor, N. Jaques, E. Nosakhare, A. Sano, and R. Picard, "Personalized Multitask Learning for Predicting Tomorrow's Mood, Stress, and Health," *IEEE Transactions on Affective Computing*, vol. 11, no. 2, pp. 200–213, 2020, doi: 10.1109/TAFFC.2017.2784832.
12. A. J. Fisher, J. D. Medaglia, and B. F. Jeronimus, "Lack of group-to-individual generalizability is a threat to human subjects research," *Proceedings of the National Academy of Sciences*, vol. 115, no. 27, pp. E6106–E6115, 2018, doi: 10.1073/pnas.1711978115.
13. S. Albanie, A. Nagrani, A. Vedaldi, and A. Zisserman, "Emotion Recognition in Speech using Cross-Modal Transfer in the Wild," in *Proceedings of the 26th ACM International Conference on Multimedia (MM '18)*, 2018, pp. 292–301, doi: 10.1145/3240508.3240578.
14. J. Ni, R. Sarbajna, Y. Liu, A. H. H. Ngu, and Y. Yan, "Cross-Modal Knowledge Distillation for Vision-to-Sensor Action Recognition," in

ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing, 2022, pp. 4448–4452, doi: 10.1109/ICASSP43922.2022.9746752.

15. C. I. Tang, I. Perez-Pozuelo, D. Spathis, S. Brage, N. Wareham, and C. Mascolo, "SelfHAR: Improving Human Activity Recognition through Self-training with Unlabeled Data," *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, vol. 5, no. 1, pp. 36:1–36:30, 2021, doi: 10.1145/3448112.
16. M. S. H. Onim, A. M. Kiselica, and H. Thapliyal, "Emotion Detection in Older Adults Using Physiological Signals from Wearable Sensors," 2025, *arXiv:2507.08167*. [Online]. Available: https://arxiv.org/abs/2507.08167
17. H. Yu and A. Sano, "Semi-Supervised Learning for Wearable-based Momentary Stress Detection in the Wild," *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, vol. 7, no. 2, pp. 83:1–83:23, 2023, doi: 10.1145/3596246.
18. Q. Xie, M. T. Luong, E. Hovy, and Q. V. Le, "Self-Training with Noisy Student Improves ImageNet Classification," in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 10684–10695, doi: 10.1109/CVPR42600.2020.01070.
19. A. Blum and T. Mitchell, "Combining Labeled and Unlabeled Data with Co-Training," in *Proceedings of the Eleventh Annual Conference on Computational Learning Theory (COLT '98)*, 1998, pp. 92–100, doi: 10.1145/279943.279962.
20. D. Angluin and P. Laird, "Learning from Noisy Examples," *Machine Learning*, vol. 2, no. 4, pp. 343–370, 1988, doi: 10.1007/BF00116829.
21. B. Frénay and M. Verleysen, "Classification in the Presence of Label Noise: A Survey," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 25, no. 5, pp. 845–869, 2014, doi: 10.1109/TNNLS.2013.2292894.
22. N. van Berkel, D. Ferreira, and V. Kostakos, "The Experience Sampling Method on Mobile Devices," *ACM Computing Surveys*, vol. 50, no. 6, pp. 93:1–93:40, 2017, doi: 10.1145/3123988.
23. G. Eisele et al., "The Effects of Sampling Frequency and Questionnaire Length on Perceived Burden, Compliance, and Careless Responding in Experience Sampling Data in a Student Population," *Assessment*, vol. 29, no. 2, pp. 136–151, 2022, doi: 10.1177/1073191120957102.
24. T. Reiter and R. Schoedel, "Never miss a beep: Using mobile sensing to investigate (non-)compliance in experience sampling studies," *Behavior Research Methods*, vol. 56, no. 4, pp. 4038–4060, 2024, doi: 10.3758/s13428-023-02252-9.
25. N. Lathia, K. K. Rachuri, C. Mascolo, and P. J. Rentfrow, "Contextual Dissonance: Design Bias in Sensor-Based Experience Sampling Methods," in *Proceedings of the 2013 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp '13)*, 2013, pp. 183–192, doi: 10.1145/2493432.2493452.
26. D. G. Horvitz and D. J. Thompson, "A Generalization of Sampling Without Replacement from a Finite Universe," *Journal of the American Statistical Association*, vol. 47, no. 260, pp. 663–685, 1952, doi: 10.1080/01621459.1952.10483446.
27. P. Klasnja et al., "Microrandomized Trials: An Experimental Design for Developing Just-in-Time Adaptive Interventions," *Health Psychology*, vol. 34, no. Suppl, pp. 1220–1228, 2015, doi: 10.1037/hea0000305.
28. L. Na, C. Yang, C. C. Lo, F. Zhao, Y. Fukuoka, and A. Aswani, "Feasibility of Reidentifying Individuals in Large National Physical Activity Data Sets From Which Protected Health Information Has Been Removed With Use of Machine Learning," *JAMA Network Open*, vol. 1, no. 8, Art. no. e186040, 2018, doi: 10.1001/jamanetworkopen.2018.6040.
29. N. Neverova et al., "Learning Human Identity From Motion Patterns," *IEEE Access*, vol. 4, pp. 1810–1820, 2016, doi: 10.1109/ACCESS.2016.2557846.
30. J. L. Kröger, P. Raschke, and T. R. Bhuiyan, "Privacy Implications of Accelerometer Data: A Review of Possible Inferences," in *Proceedings of the 3rd International Conference on Cryptography, Security and Privacy (ICCSP 2019)*, 2019, pp. 81–87, doi: 10.1145/3309074.3309076.
31. M. Malekzadeh, R. G. Clegg, A. Cavallaro, and H. Haddadi, "Mobile Sensor Data Anonymization," in *Proceedings of the International Conference on Internet of Things Design and Implementation (IoTDI '19)*, 2019, pp. 49–58, doi: 10.1145/3302505.3310068.
32. R. Shokri, M. Stronati, C. Song, and V. Shmatikov, "Membership Inference Attacks Against Machine Learning Models," in *2017 IEEE Symposium on Security and Privacy (SP)*, 2017, pp. 3–18, doi: 10.1109/SP.2017.41.
33. L. Melis, C. Song, E. De Cristofaro, and V. Shmatikov, "Exploiting Unintended Feature Leakage in Collaborative Learning," in *2019 IEEE Symposium on Security and Privacy (SP)*, 2019, pp. 691–706, doi: 10.1109/SP.2019.00029.
34. M. Abadi et al., "Deep Learning with Differential Privacy," in *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security (CCS '16)*, 2016, pp. 308–318, doi: 10.1145/2976749.2978318.
35. M. Benouis, E. André, and Y. S. Can, "Balancing Between Privacy and Utility for Affect Recognition Using Multitask Learning in Differential Privacy-Added Federated Learning Settings: Quantitative Study," *JMIR Mental Health*, vol. 11, Art. no. e60003, 2024, doi: 10.2196/60003.

저자 소개

강정모 서일대학교 정보통신공학과 학부생이다. [약력 TO FILL: 학위 연도, 연구 관심사.]

김완태 서일대학교 정보통신공학과에 재직 중이다. [약력 TO FILL: 직위, 학위, 연구 관심사.]